technische universität
dortmund

Betriebssysteme (BS)

Dateisysteme

http://ess.cs.tu-dortmund.de/DE/Teaching/SS2017/BS/

Olaf Spinczyk

olaf.spinczyk@tu-dortmund.de
http://ess.cs.tu-dortmund.de/~os

AG Eingebettete Systemsoftware
Informatik 12, TU Dortmund

Inhalt

- Wiederholung
- Dateien
- Freispeicherverwaltung
- Verzeichnisse
- Dateisysteme
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- Zusammenfassung

Silberschatz, Kap. ...
10: *File System*
11: *Implementing File Systems*

Tanenbaum, Kap. ...
6: Dateisysteme

Inhalt

- **Wiederholung**
- Dateien
- Freispeicherverwaltung
- Verzeichnisse
- Dateisysteme
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- Zusammenfassung

Wiederholung

- In den bisherigen Vorlesungen
  - CPU, Hauptspeicher
- In der letzten Vorlesung
  - E/A-Geräte, insbesondere auch Zugriff auf blockorientierte Geräte
- **Heute: Dateisysteme**

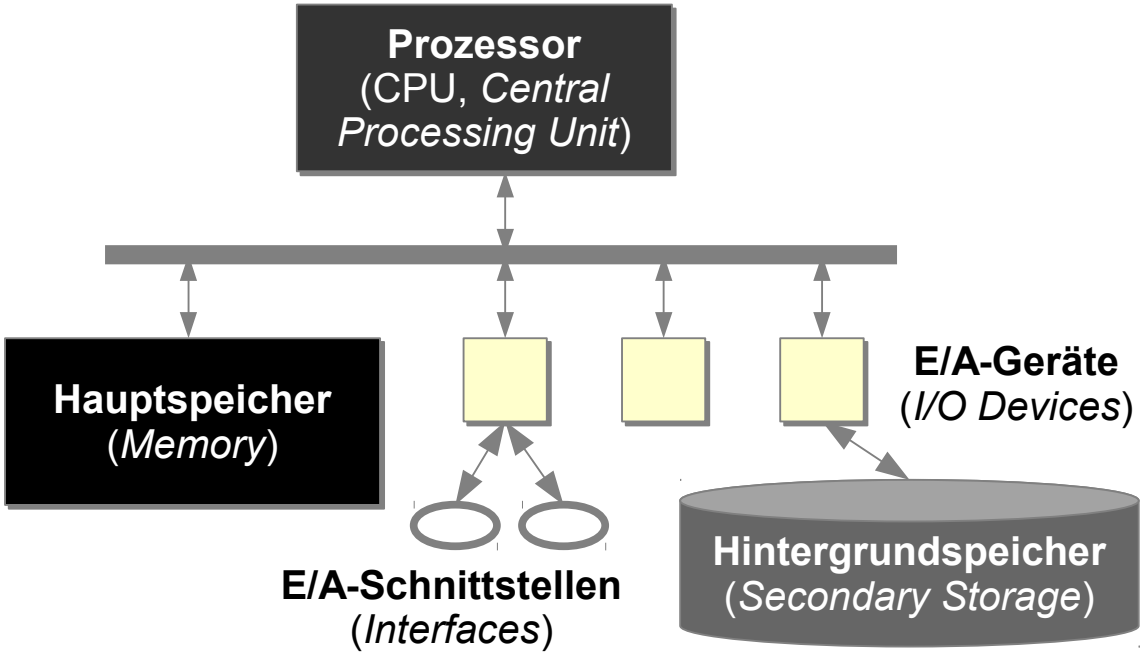

Hintergrundspeicher

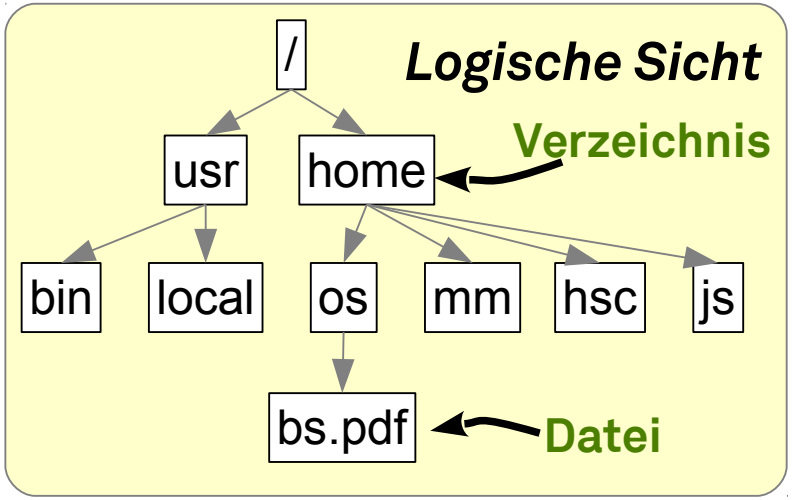

Dateisysteme erlauben die dauerhafte Speicherung großer Datenmengen.

Abbildung

Physikalische Sicht

Festplatte mit 6 Oberflächen

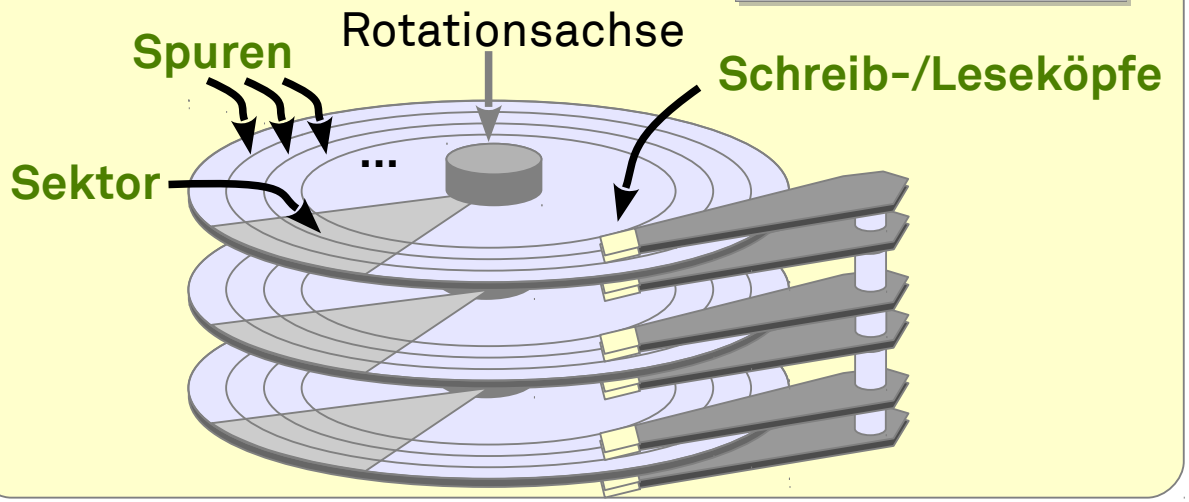

Das Betriebssystem stellt den Anwendungen die logische Sicht zur Verfügung und muss diese effizient realisieren.

Inhalt

- Wiederholung
- **Dateien**
- Freispeicherverwaltung
- Verzeichnisse
- Dateisysteme
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- Zusammenfassung

Speicherung von Dateien

- Dateien benötigen oft mehr als einen Block auf der Festplatte
  - Welche Blöcke werden für die Speicherung einer Datei verwendet?

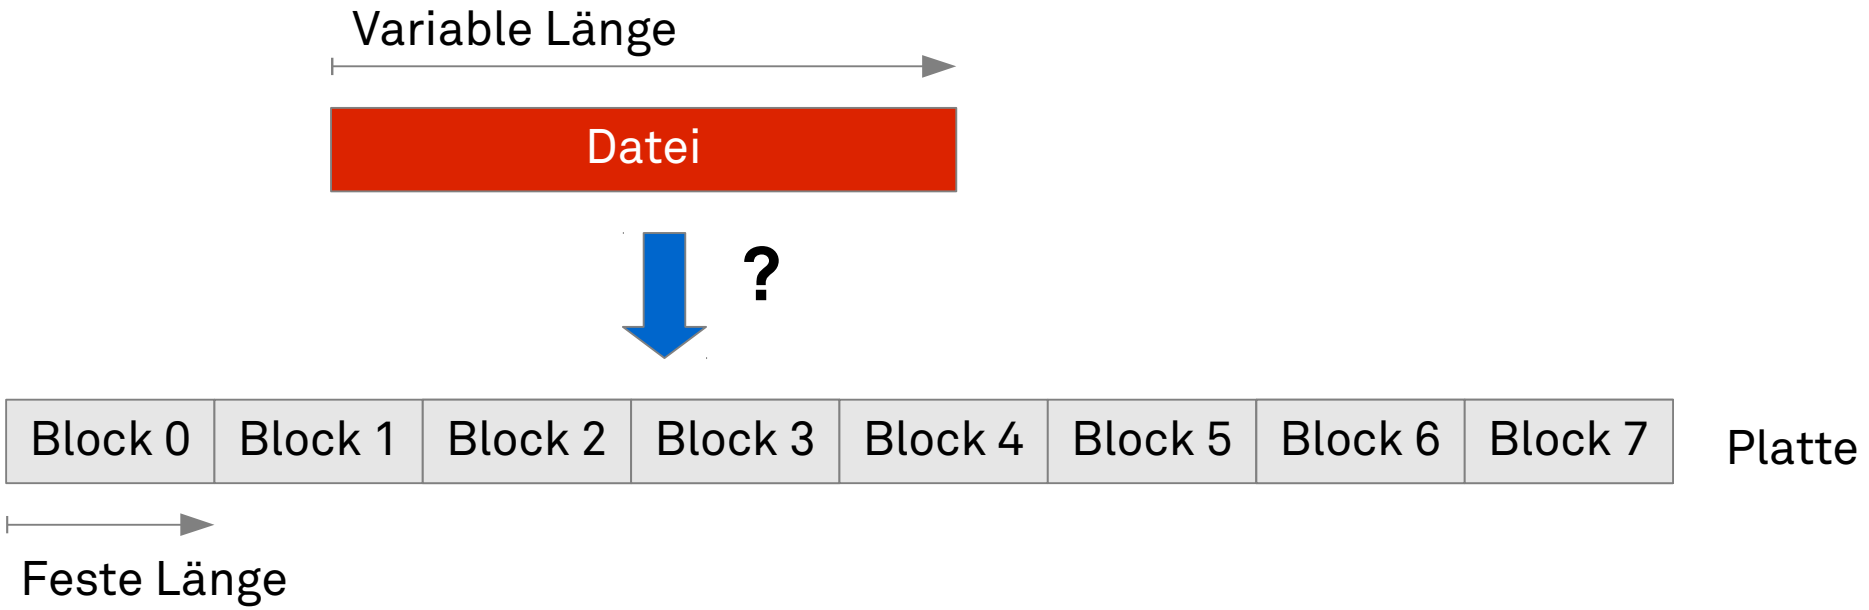

Kontinuierliche Speicherung

- Datei wird in Blöcken mit aufsteigenden Blocknummern gespeichert
  - Nummer des ersten Blocks und Anzahl der Folgeblöcke muss gespeichert werden, z.B. Start: Block 4; Länge: 3.

Block 0	Block 1	Block 2	Block 3	Block 4	Block 5	Block 6	Block 7

- Vorteile
  - Zugriff auf alle Blöcke mit minimaler Positionierzeit des Schwenkarms
  - Schneller direkter Zugriff auf bestimmter Dateiposition
  - Einsatz z.B. bei nicht modifizierbaren Dateisystemen wie auf CDs/DVDs

Kontinuierliche Speicherung: Probleme

- **Finden des freien Platzes** auf der Festplatte (Menge aufeinanderfolgender und freier Plattenblöcke)
- **Fragmentierungsproblem** (Verschnitt: nicht nutzbare Plattenblöcke; siehe auch Speicherverwaltung)
- **Größe bei neuen Dateien** oft nicht im Voraus bekannt
- **Erweitern** ist problematisch
- **Umkopieren**, falls kein freier angrenzender Block mehr verfügbar

Verkettete Speicherung

- Blöcke einer Datei sind verkettet

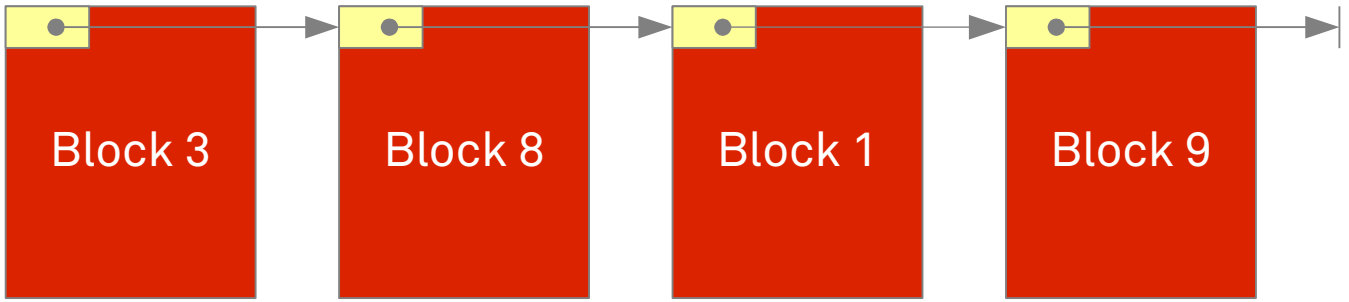

  - z.B. Commodore Systeme (CBM 64 etc.)
    - Blockgröße 256 Bytes
    - die ersten zwei Bytes bezeichnen Spur- und Sektornummer des nächsten Blocks
    - wenn Spurnummer gleich Null: letzter Block
    - 254 Bytes Nutzdaten

→ Datei kann vergrößert und verkleinert werden

Verkettete Speicherung: Probleme

- **Speicher für Verzeigerung** geht von den Nutzdaten im Block ab
  - Ungünstig im Zusammenhang mit *Paging*: Seite würde immer aus Teilen von zwei Plattenblöcken bestehen
- **Fehleranfälligkeit**: Datei ist nicht restaurierbar, falls einmal Verzeigerung fehlerhaft
- **Schlechter direkter Zugriff** auf bestimmte Dateiposition
- **Häufiges Positionieren** des Schreib-, Lesekopfs bei verstreuten Datenblöcken

Verkettete Speicherung: FAT

- Verkettung wird in separaten Plattenblöcken gespeichert
  - FAT-Ansatz (FAT: ***File Allocation Table***)
    - z.B. MS-DOS, Windows 95

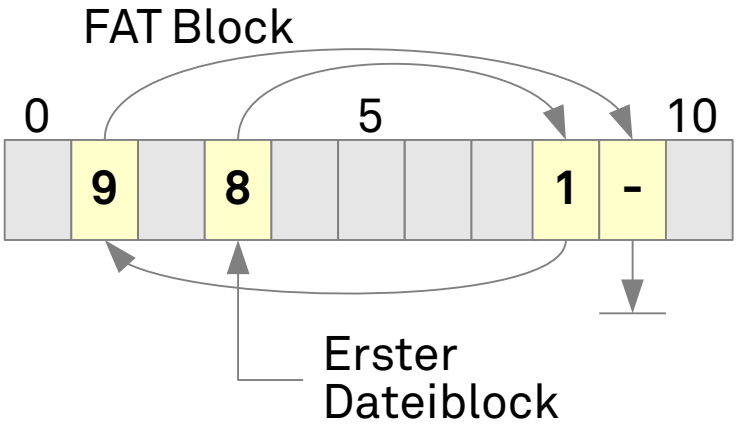

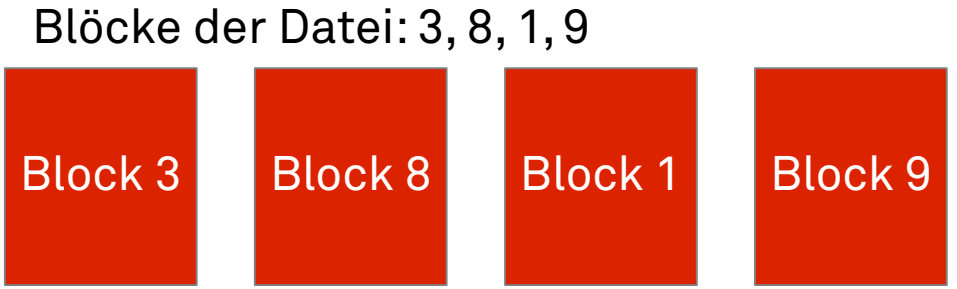

- Vorteile
  - kompletter Inhalt des Datenblocks ist nutzbar
  - mehrfache Speicherung der FAT möglich: Einschränkung der Fehleranfälligkeit

Verkettete Speicherung: Probleme (2)

- **Zusätzliches Laden** mindestens eines Blocks
  (*Caching* der FAT zur Effizienzsteigerung nötig)
- **Laden unbenötigter Informationen**: FAT enthält Verkettungen für alle Dateien
- **Aufwändige Suche** nach dem zugehörigen Datenblock bei bekannter Position in der Datei
- **Häufiges Positionieren** des Schreib-, Lesekopfs bei verstreuten Datenblöcken

Diskussion: *Chunks/Extents/Clusters*

- Variation
  - Unterteilen einer Datei in kontinuierlich gespeicherte **Folgen** von Blöcken (*Chunk*, *Extent* oder *Cluster* genannt)
  - Reduziert die Zahl der Positionierungsvorgänge
  - Blocksuche wird linear in Abhängigkeit von der *Chunk*-Größe beschleunigt
- Probleme
  - Zusätzliche Verwaltungsinformationen
  - Verschnitt
    - Feste Größe: innerhalb einer **Folge** (interner Verschnitt)
    - Variable Größe: außerhalb der Folgen (externer Verschnitt)

→ Wird eingesetzt, bringt aber keinen fundamentalen Fortschritt

Indiziertes Speichern

- Spezieller Plattenblock enthält Blocknummern der Datenblocks einer Datei

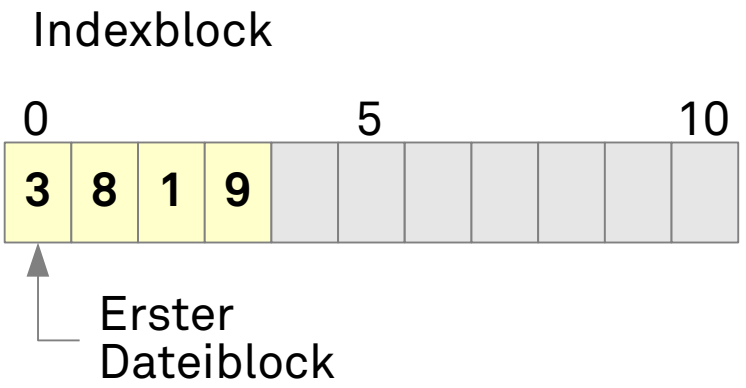

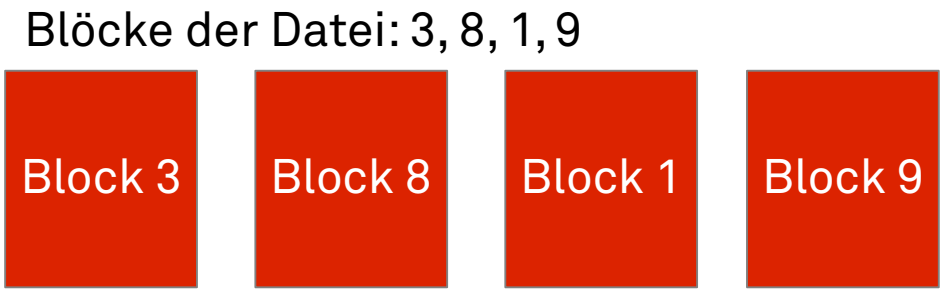

- Problem
  - Feste Anzahl von Blöcken im Indexblock
    - Verschnitt bei kleinen Dateien
    - Erweiterung nötig für große Dateien

Indiziertes Speichern: UNIX-Inode

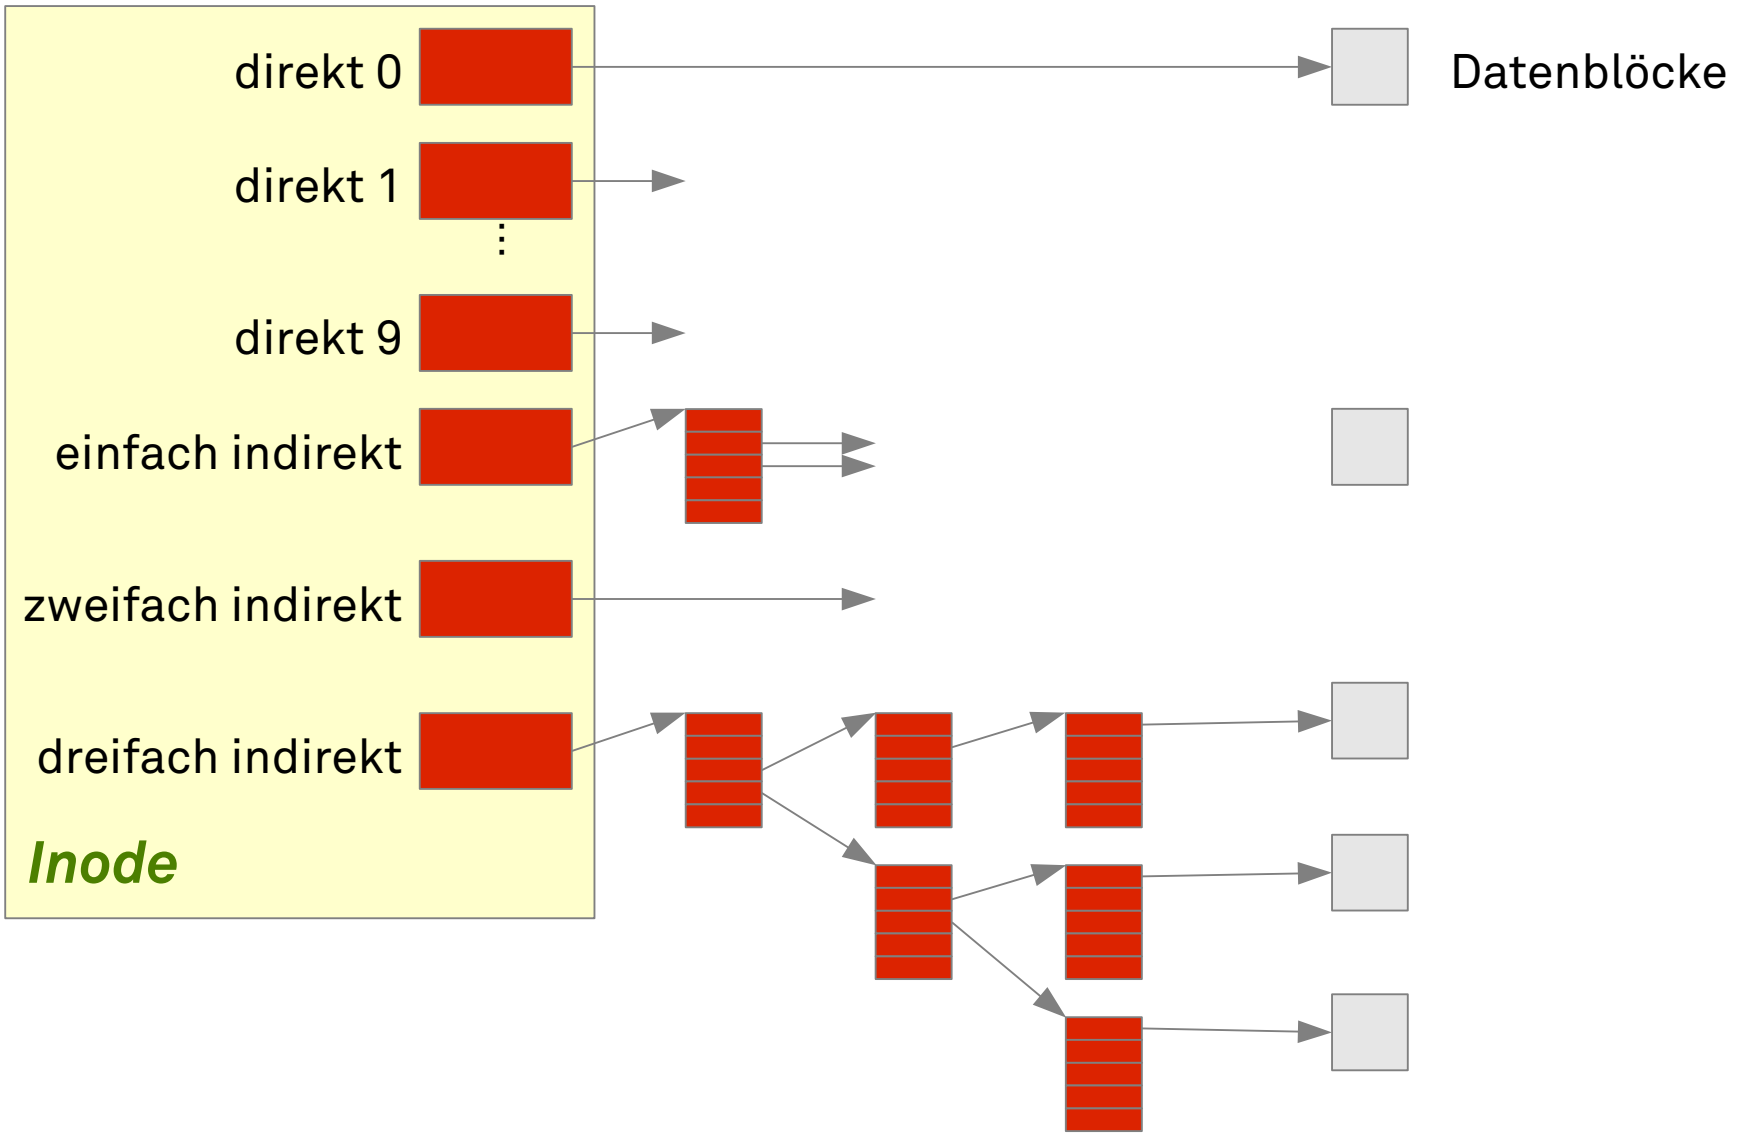

Indiziertes Speichern: Diskussion

- Einsatz von mehreren Stufen der Indizierung
  - Inode benötigt sowieso einen Block auf der Platte (Verschnitt unproblematisch bei kleinen Dateien)
  - durch mehrere Stufen der Indizierung auch große Dateien adressierbar
- Nachteil
  - mehrere Blöcke müssen geladen werden (nur bei langen Dateien)

Baumsequentielle Speicherung

- Wird bei Datenbanken zum effizienten Auffinden eines Datensatzes mit Hilfe eines Schlüssels eingesetzt
  - Schlüsselraum darf spärlich besetzt sein.
- Kann auch verwendet werden, um Datei-*Chunks* mit bestimmtem Datei-*Offset* aufzufinden, z.B. NTFS, Reiser FS, btrfs, IBM JFS2 Dateisystem (B+ Baum)

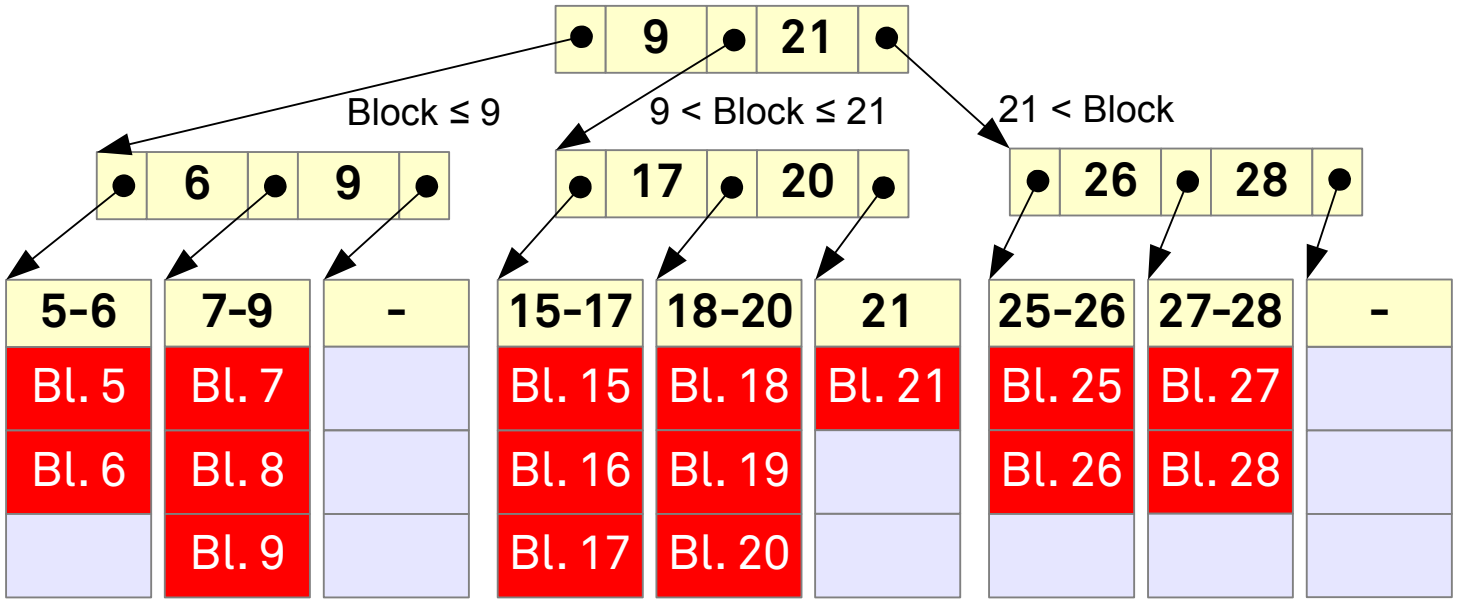

Inhalt

- Wiederholung
- Dateien
- **Freispeicherverwaltung**
- Verzeichnisse
- Dateisysteme
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- Zusammenfassung

Freispeicherverwaltung

Ähnlich wie Verwaltung von freiem Hauptspeicher

- **Bitvektoren** zeigen für jeden Block Belegung an
- **Verkettete Listen** repräsentieren freie Blöcke
  - Verkettung kann in den freien Blöcken vorgenommen werden
  - Optimierung: aufeinanderfolgende Blöcke werden nicht einzeln aufgenommen, sondern als Stück verwaltet
  - Optimierung: ein freier Block enthält viele Blocknummern weiterer freier Blöcke und evtl. die Blocknummer eines weiteren Blocks mit den Nummern freier Blöcke

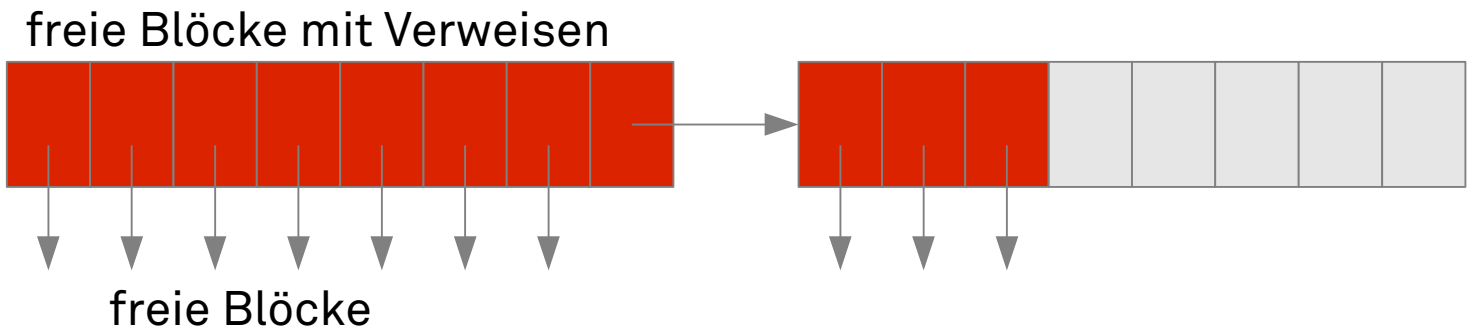

Freispeicherverwaltung (2)

- **Baumsequentielle Speicherung** freier Blockfolgen
  - Erlaubt schnelle Suche nach freier Blockfolge bestimmter Größe
  - Anwendung z.B. im SGI XFS

Inhalt

- Wiederholung
- Dateien
- Freispeicherverwaltung
- **Verzeichnisse**
- Dateisysteme
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- Zusammenfassung

Verzeichnis als Liste

- Einträge gleicher Länge hintereinander in einer Liste, z.B.
  - ***FAT File systems***

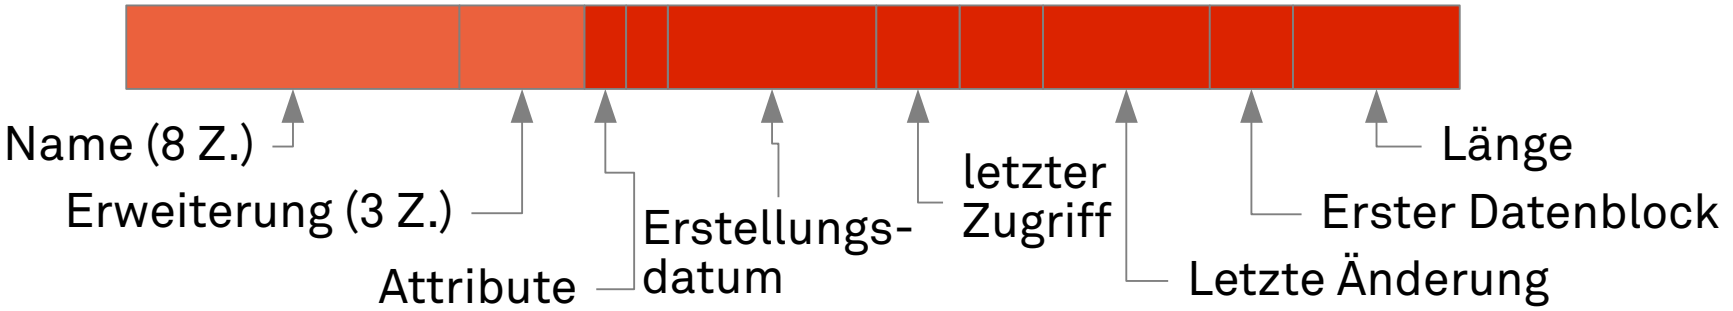

    - für **VFAT** werden mehrere Einträge zusammen verwendet, um den langen Namen aufzunehmen

  - ***UNIX System V.3***

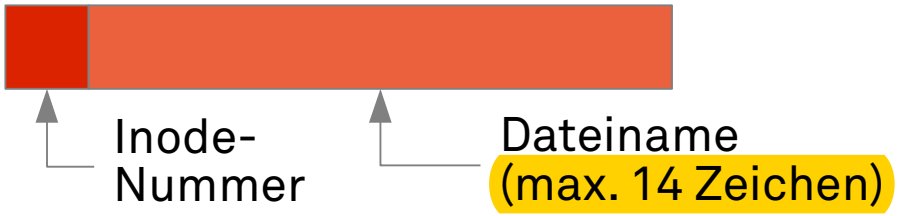

- **Problem**
  - Suche nach bestimmten Eintrag muss linear erfolgen
  - Bei Sortierung der Liste: Schnelles Suchen, Aufwand beim Einfügen

Einsatz von *Hash*-Funktionen

- Funktion bildet Dateinamen auf einen Index in die Katalogliste ab. Schnellerer Zugriff auf den Eintrag möglich (kein lineares Suchen)
- (Einfaches aber schlechtes) Beispiel: (∑ Zeichen) mod N

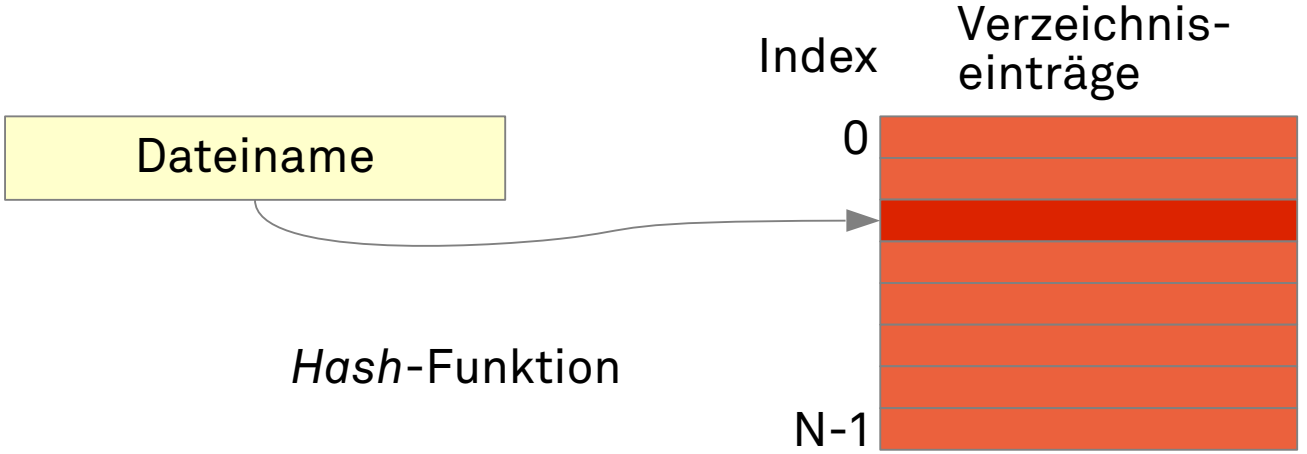

- **Probleme**
  - Kollisionen (mehrere Dateinamen werden auf gleichen Eintrag abgebildet)
  - Anpassung der Listengröße, wenn Liste voll

Variabel lange Listenelemente

- Beispiel ***4.2 BSD***, ***System V Rel. 4***, u.a.

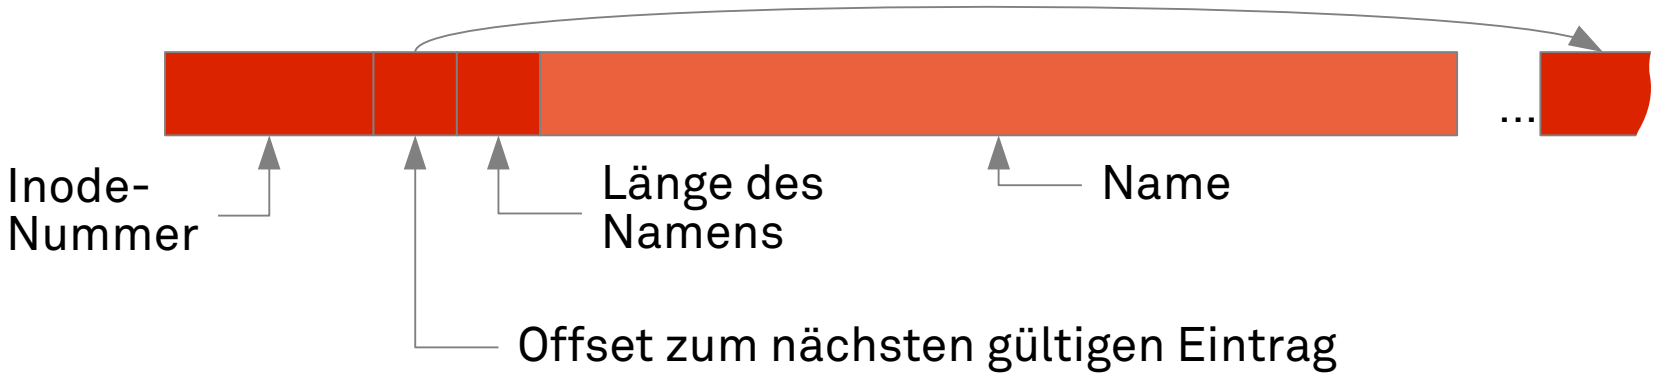

- **Probleme**
  - Verwaltung von freien Einträgen in der Liste
  - Speicherverschnitt (Kompaktifizieren, etc.)

Inhalt

- Wiederholung
- Dateien
- Freispeicherverwaltung
- Verzeichnisse
- **Dateisysteme**
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- Zusammenfassung

UNIX System V File System

- Blockorganisation

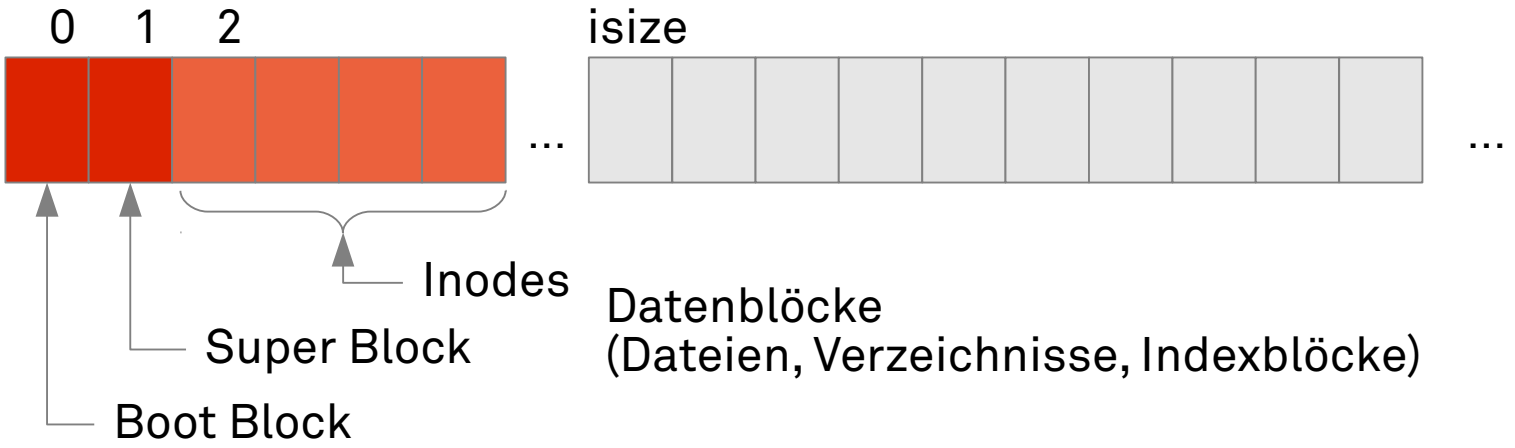

  - ***Boot Block*** enthält Informationen zum Laden Betriebssystems
  - ***Super Block*** enthält Verwaltungsinformation für ein Dateisystem
    - Anzahl der Blöcke, Anzahl der ***Inodes***
    - Anzahl und Liste freier Blöcke und freier ***Inodes***
    - Attribute (z.B. ***Modified flag***)

BSD 4.2 (*Berkeley Fast File System*)

- Blockorganisation

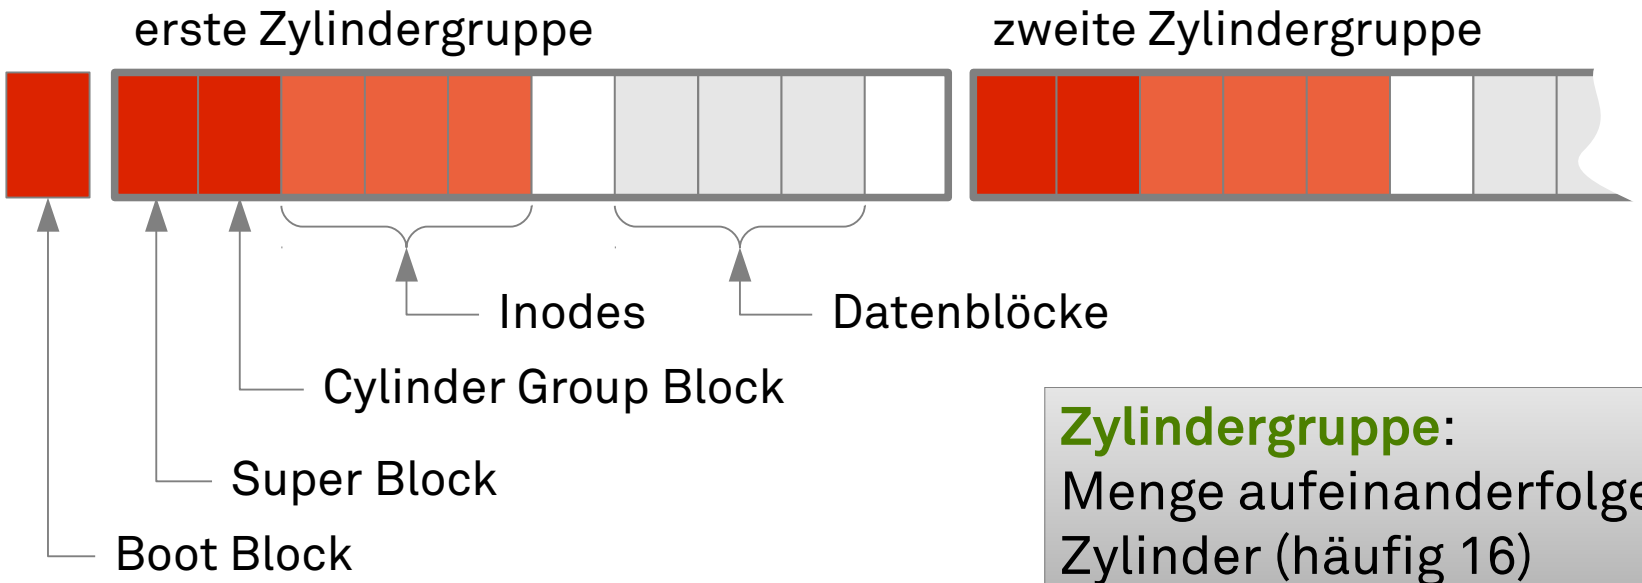

Zylindergruppe:
Menge aufeinanderfolgender Zylinder (häufig 16)

  - Kopie des Super Blocks in jeder Zylindergruppe
  - Eine Datei wird möglichst innerhalb einer Zylindergruppe gespeichert

- Vorteil: kürzere Positionierungszeiten

Linux Ext2/3/4 File System

- Blockorganisation

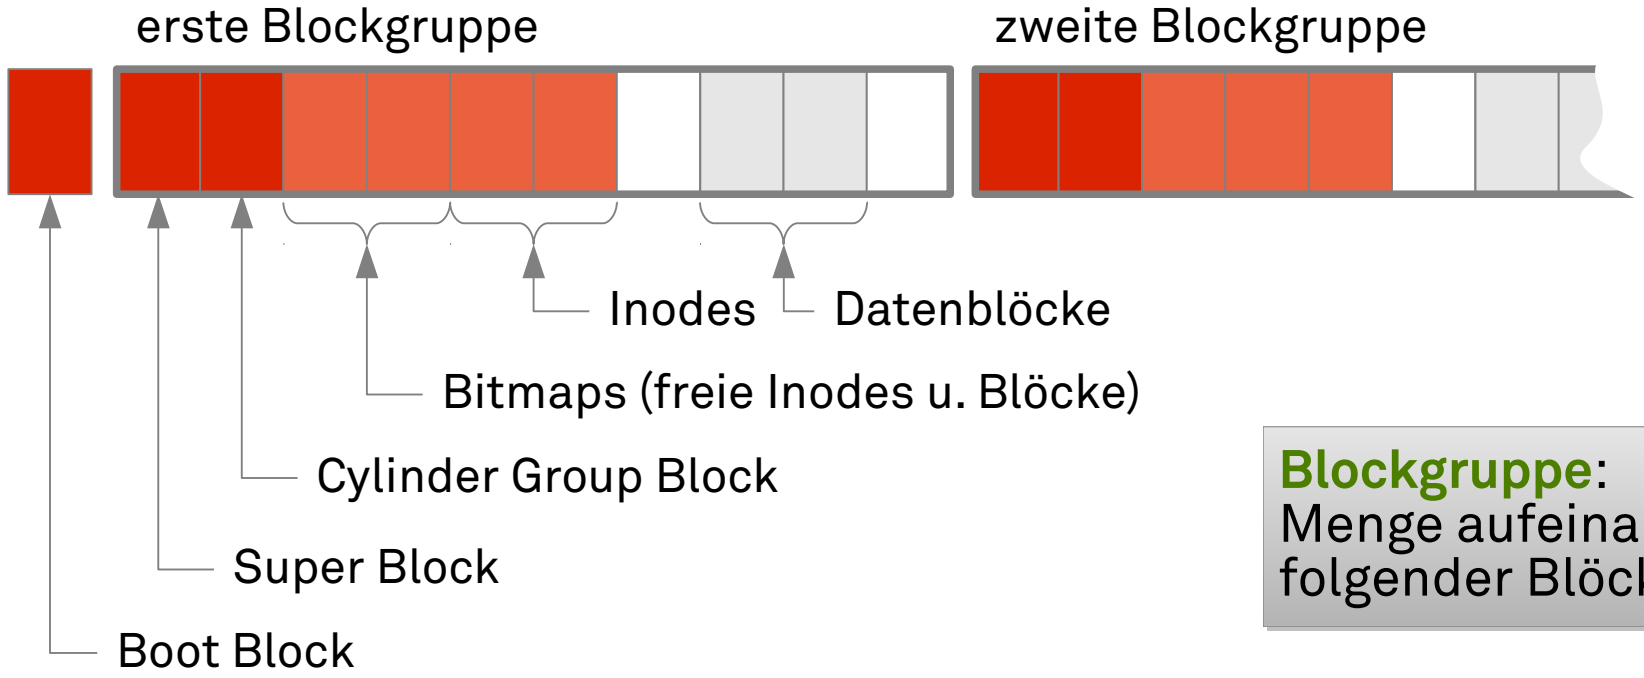

Blockgruppe: Menge aufeinander folgender Blöcke

  - Ähnliches Layout wie BSD FFS
  - Blockgruppen unabhängig von Zylindern

Inhalt

- Wiederholung
- Dateien
- Freispeicherverwaltung
- Verzeichnisse
- Dateisysteme
- **Pufferspeicher**
- Dateisysteme mit Fehlererholung
- Zusammenfassung

UNIX Block Buffer Cache

- Pufferspeicher für Plattenblöcke im Hauptspeicher
  - Verwaltung mit Algorithmen ähnlich wie bei Kachelverwaltung
  - ***Read ahead***: beim sequentiellen Lesen wird auch der Transfer von Folgeblöcken angestoßen
  - ***Lazy write***: Block wird nicht sofort auf Platte geschrieben (erlaubt Optimierung der Schreibzugriffe und blockiert den Schreiber nicht)
  - Verwaltung freier Blöcke in einer Freiliste
    - Kandidaten für Freiliste werden nach LRU Verfahren bestimmt
    - Bereits freie aber noch nicht anderweitig benutzte Blöcke können reaktiviert werden (***Reclaim***)

UNIX Block Buffer Cache (2)

- Schreiben erfolgt, wenn
  - keine freien Puffer mehr vorhanden sind,
  - regelmäßig vom System (**fsflush** Prozess, **update** Prozess),
  - beim Systemaufruf **sync**(),
  - und nach jedem Schreibaufruf im Modus O_SYNC.

- Adressierung
  - Adressierung eines Blocks erfolgt über ein Tupel: (Gerätenummer, Blocknummer)
  - Über die Adresse wird ein *Hash*-wert gebildet, der eine der möglichen Pufferlisten auswählt

UNIX Block Buffer Cache: Aufbau

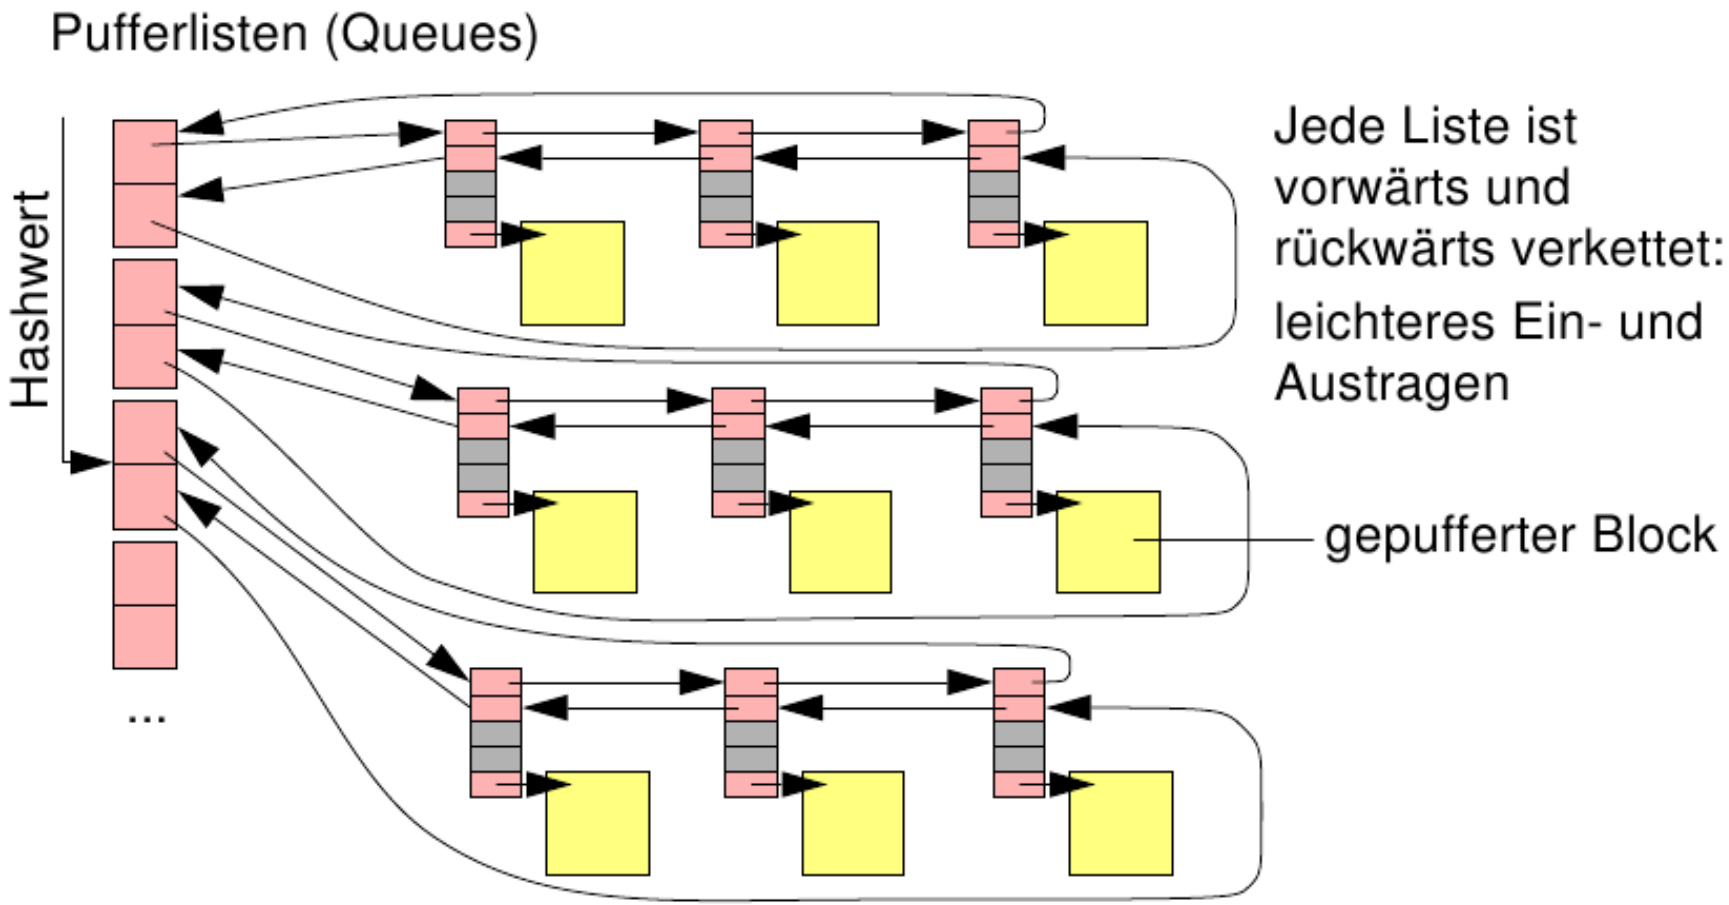

UNIX Block Buffer Cache: Aufbau (2)

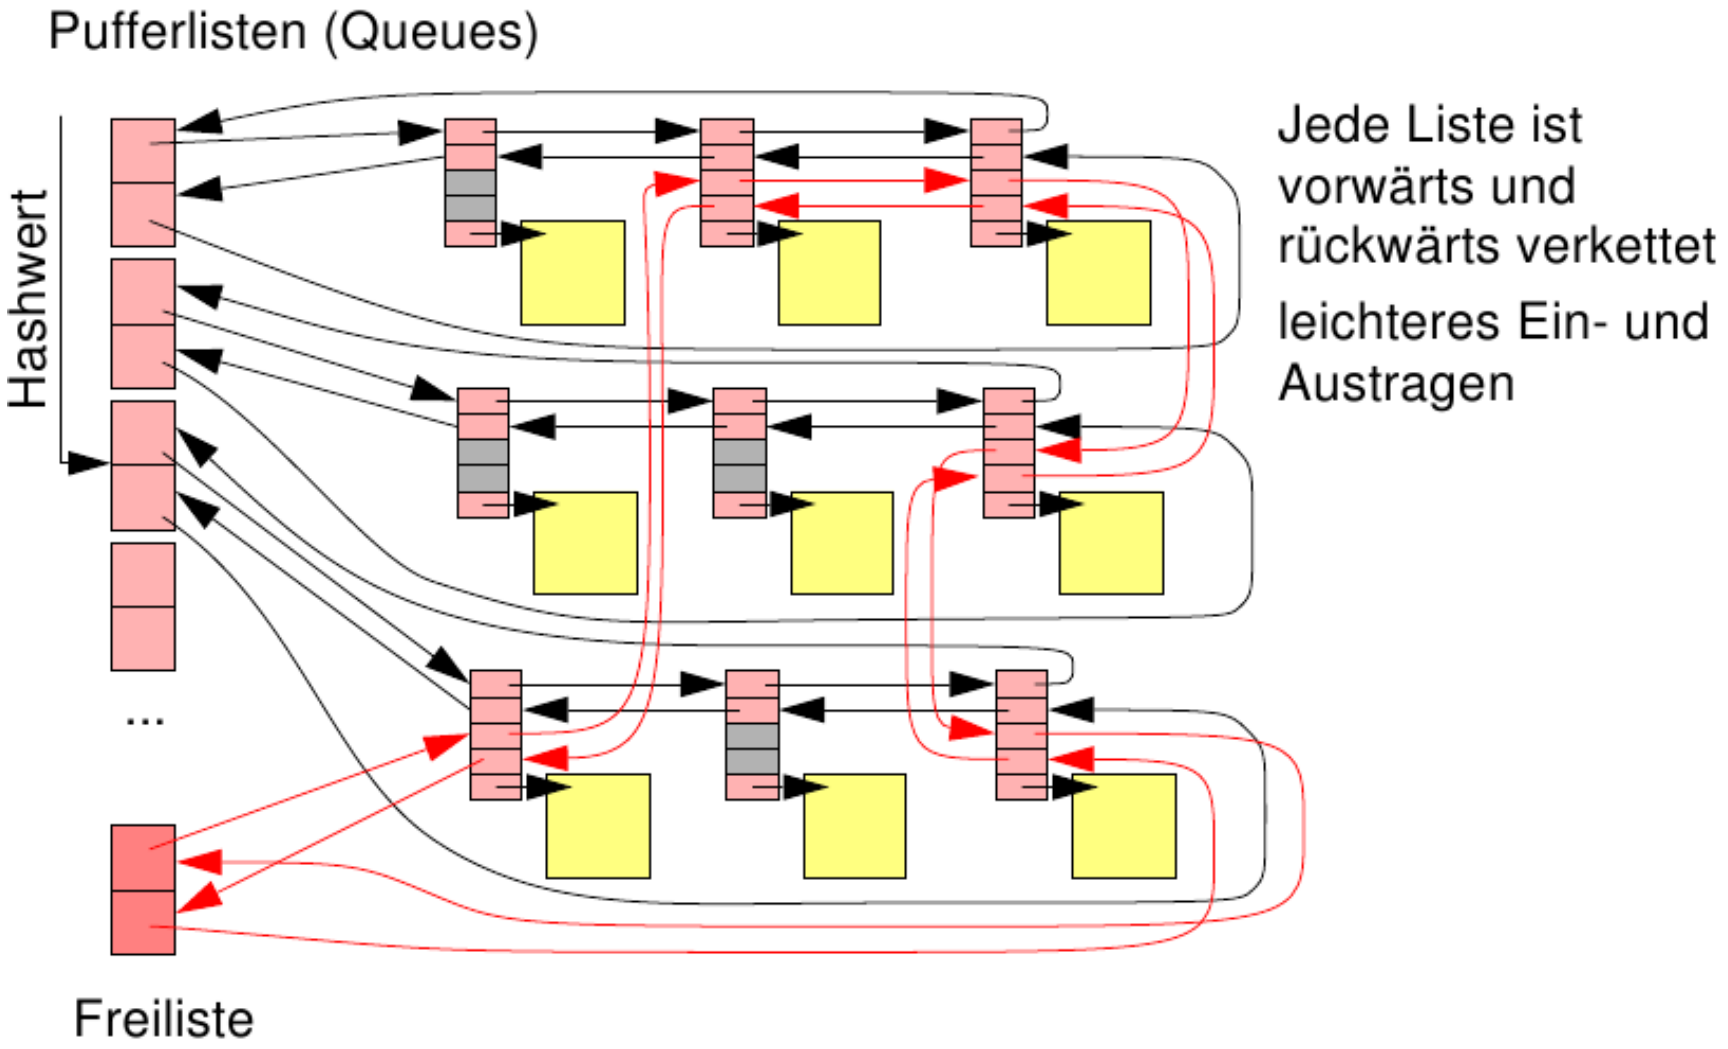

Inhalt

- Wiederholung
- Dateien
- Freispeicherverwaltung
- Verzeichnisse
- Dateisysteme
- Pufferspeicher
- **Dateisysteme mit Fehlererholung**
- Zusammenfassung

Dateisysteme mit Fehlererholung

- Mögliche Fehler
  - Stromausfall (ahnungsloser Benutzer schaltet einfach Rechner aus)
  - Systemabsturz
- Auswirkungen auf das Dateisystem
  - inkonsistente Metadaten
    z.B. Katalogeintrag fehlt zur Datei oder umgekehrt
    z.B. Block ist benutzt aber nicht als belegt markiert

→ **Reparaturprogramme**

  - Programme wie **chkdsk**, **scandisk** oder **fsck** können inkonsistente Metadaten reparieren

- Probleme
  - Datenverluste bei Reparatur möglich
  - Lange Laufzeiten der Reparaturprogramme bei großen Platten

Journaled File Systems

- Zusätzlich zum Schreiben der Daten und Meta-Daten (z.B. *Inodes*) wird ein Protokoll der Änderungen geführt
  - Alle Änderungen treten als Teil von **Transaktionen** auf.
  - Beispiele für Transaktionen:
    - Erzeugen, löschen, erweitern, verkürzen von Dateien
    - Dateiattribute verändern
    - Datei umbenennen
  - Protokollieren aller Änderungen am Dateisystem zusätzlich in einer Protokolldatei (***Log File***)
  - Beim Bootvorgang wird Protokolldatei mit den aktuellen Änderungen abgeglichen und damit werden Inkonsistenzen vermieden.

Journaled File Systems: Protokoll

- Für jeden Einzelvorgang einer Transaktion wird zunächst ein Protokolleintrag erzeugt und ...
- danach die Änderung am Dateisystem vorgenommen.
- Dabei gilt:
  - Der Protokolleintrag wird immer **vor** der eigentlichen Änderung auf Platte geschrieben.
  - Wurde etwas auf Platte geändert, steht auch der Protokolleintrag dazu auf der Platte.

Journaled File Systems: Erholung

- Beim Bootvorgang wird überprüft, ob die protokollierten Änderungen vorhanden sind:
  - Transaktion kann wiederholt bzw. abgeschlossen werden, falls alle Protokolleinträge vorhanden. → ***Redo***
  - Angefangene aber nicht beendete Transaktionen werden rückgängig gemacht → ***Undo***.

Journaled File Systems: Ergebnis

- Vorteile
  - eine Transaktion ist entweder vollständig durchgeführt oder gar nicht
  - Benutzer kann ebenfalls Transaktionen über mehrere Dateizugriffe definieren, wenn diese ebenfalls im Log erfasst werden.
  - keine inkonsistenten Metadaten möglich
  - Hochfahren eines abgestürzten Systems benötigt nur den relativ kurzen Durchgang durch das Log-File.
    - Alternative **chkdsk** benötigt viel Zeit bei großen Platten
- Nachteile
  - ineffizienter, da zusätzliches Log-File geschrieben wird
    - daher meist nur „Metadata Journaling“, kein „Full Journaling“
- Beispiele: NTFS, EXT3, ReiserFS

Inhalt

- Wiederholung
- Dateien
- Freispeicherverwaltung
- Verzeichnisse
- Dateisysteme
- Pufferspeicher
- Dateisysteme mit Fehlererholung
- **Zusammenfassung**

Zusammenfassung: Dateisysteme

- ... sind eine **Betriebssystemabstraktion**
  - Speicherung logisch zusammenhängender Informationen als Datei
  - Meist hierarchische Verzeichnisstruktur, um Dateien zu ordnen
- ... werden durch die **Hardware beeinflusst**
  - Minimierung der Positionierungszeiten bei Platten
  - Gleichmäßige „Abnutzung“ bei FLASH-Speicher
  - Kein *Buffer*-Cache bei RAM-Disks
- ... werden durch das **Anwendungsprofil beeinflusst**
  - Blockgröße
    - zu klein → Verwaltungsstrukturen können zu *Performance*-Verlust führen
    - zu groß → Verschnitt führt zu Plattenplatzverschwendung
  - Aufbau von Verzeichnissen
    - keine *Hash*-Funktion → langwierige Suche
    - mit *Hash*-Funktion → mehr Aufwand bei der Verwaltung