



## Datenstrukturen, Algorithmen und Programmierung 2 (DAP2)

## Approximationsalgorithmen

### *Das (diskrete) $k$ -Center Clustering Problem*

- Gegeben: Menge  $P$  von  $n$  Punkten in der Ebene
- Gesucht: Menge  $C \subseteq P$  von  $k$  Zentren, so dass die maximale Distanz der Punkte zum nächstgelegenen Zentrum, d.h.  
$$\text{cost}(P, C) = \max_{p \in P} d(p, C)$$
 minimiert wird, wobei
- $\text{dist}(p, C) = \max_{q \in C} \text{dist}(p, q)$  und
- $\text{dist}(p, q)$  bezeichnet den Abstand (Euklidische Distanz) von  $p$  und  $q$


# Approximationsalgorithmen

## *Beispiel*



## Approximationsalgorithmen

### *Beispiel*



### *Alternative Formulierung*

Finde  $k$  Scheiben mit Zentrum aus  $P$ , die alle Punkte abdecken und deren Maximaler Radius minimiert wird.

## Approximationsalgorithmen

### *Typische Anwendung*

- Punkte symbolisieren Städte
- Will Mobilfunkmasten mit möglichst geringer Leistung aufstellen, so dass alle Städte versorgt sind

### *Allgemeiner*

- Punkte (typischerweise in höheren Dimensionen) sind „Beschreibungen von Objekten“
- Will Objekte in Gruppen von ähnlichen Objekten unterteilen

## Approximationsalgorithmen


### *Ein Gedankenexperiment*

- Nehmen wir an, wir kennen die Kosten  $r$  einer optimalen Lösung, d.h. wir wissen, dass man mit Scheiben mit Radius  $r$  und Zentrum aus  $P$  die Punkte abdecken kann
- Wir werden zeigen, dass wir dann einen einfachen 2-Approximationsalgorithmus finden können

## Approximationsalgorithmen

### Idee


- Wir nutzen Existenz von Lösung  $C^*$  mit Radius (Kosten)  $r$
- Betrachte Punkt  $p \in P$
- Dann gibt es Zentrum  $c^* \in C^*$  mit  $\text{dist}(p, c^*) \leq r$
- Nehmen wir nun  $p$  als Zentrum anstelle von  $c^*$  und verdoppeln wir den Radius, so decken wir jeden Punkt  $q$  ab, der von  $c^*$  mit Radius  $r$  abgedeckt wurde, d.h.
- für jedes  $q \in P$  mit  $\text{dist}(q, c^*) \leq r$  gilt  $\text{dist}(p, q) \leq \text{dist}(p, c^*) + \text{dist}(c^*, q) \leq 2r$



## Approximationsalgorithmen

### Idee

- Wir nutzen Existenz von Lösung  $C^*$  mit Radius (Kosten)  $r$
- Betrachte Punkt  $p \in P$
- Dann gibt es Zentrum  $c^* \in C^*$  mit  $\text{dist}(p, c^*) \leq r$
- Nehmen wir nun  $p$  als Zentrum anstelle von  $c^*$  und verdoppeln wir den Radius, so decken wir jeden Punkt  $q$  ab, der von  $c^*$  mit Radius  $r$  abgedeckt wurde, d.h.
- für jedes  $q \in P$  mit  $\text{dist}(q, c^*) \leq r$  gilt  $\text{dist}(p, q) \leq \text{dist}(p, c^*) + \text{dist}(c^*, q) \leq 2r$





## Approximationsalgorithmen

$k$ -Center1( $P, k$ )

1.  $C \leftarrow \emptyset; P' \leftarrow P$
2. **while**  $P' \neq \emptyset$  **do**
3.     Wähle beliebigen Punkt  $p \in P'$
4.      $C \leftarrow C \cup \{p\}$
5.     Lösche alle Punkte aus  $P'$  mit Distanz höchstens  $2r$  von  $p$
6. **if**  $|C| \leq k$  **then return**  $C$
7. **else return** „Es gibt keine Menge von  $k$  Zentren mit Radius  $r$ “

## Approximationsalgorithmen

$k$ -Center1( $P, k$ )

1.  $C \leftarrow \emptyset; P' \leftarrow P$
2. **while**  $P' \neq \emptyset$  **do**
3.     Wähle beliebigen Punkt  $p \in P'$
4.      $C \leftarrow C \cup \{p\}$
5.     Lösche alle Punkte aus  $P'$  mit Distanz höchstens  $2r$  von  $p$
6. **if**  $|C| \leq k$  **then return**  $C$
7. **else return** „Es gibt keine Menge von  $k$  Zentren mit Radius  $r$ “

*Offensichtlich gilt*

Jede Menge von  $k$  Zentren, die der Algorithmus zurückgibt, hat Kosten höchstens  $2r$ .

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- **Annahme:** Es gibt  $C^*$  mit  $\text{cost}(P, C^*) \leq r$  und  $|C^*| \leq k$  und  $|C| > k$ .

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Annahme: Es gibt  $C^*$  mit  $\text{cost}(P, C^*) \leq r$  und  $|C^*| \leq k$  und  $|C| > k$ .
- Sei  $C$  die Menge der Zentren, die  $k$ -Center1 auswählt

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Annahme: Es gibt  $C^*$  mit  $\text{cost}(P, C^*) \leq r$  und  $|C^*| \leq k$  und  $|C| > k$ .
- Sei  $C$  die Menge der Zentren, die  $k$ -Center1 auswählt
- Da  $C \subseteq P$  gibt es für jedes  $p \in C$  (mindestens) ein  $c^* \in C^*$  mit  $\text{dist}(p, c^*) \leq r$
- Wir nennen  $c^*$  nah zu  $p$

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Annahme: Es gibt  $C^*$  mit  $\text{cost}(P, C^*) \leq r$  und  $|C^*| \leq k$  und  $|C| > k$ .
- Sei  $C$  die Menge der Zentren, die  $k$ -Center1 auswählt
- Da  $C \subseteq P$  gibt es für jedes  $p \in C$  (mindestens) ein  $c^* \in C^*$  mit  $\text{dist}(p, c^*) \leq r$
- Wir nennen  $c^*$  nah zu  $p$
- **Behauptung: Kein  $c^*$  kann nah zu zwei  $p \in C$  sein (Beweis später)**

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Annahme: Es gibt  $C^*$  mit  $\text{cost}(P, C^*) \leq r$  und  $|C^*| \leq k$  und  $|C| > k$ .
- Sei  $C$  die Menge der Zentren, die  $k$ -Center1 auswählt
- Da  $C \subseteq P$  gibt es für jedes  $p \in C$  (mindestens) ein  $c^* \in C^*$  mit  $\text{dist}(p, c^*) \leq r$
- Wir nennen  $c^*$  nah zu  $p$
- Behauptung: Kein  $c^*$  kann nah zu zwei  $p \in C$  sein (Beweis später)
- **Damit folgt:  $|C^*| \geq |C|$  und somit Widerspruch zu  $|C^*| \leq k$  und  $|C| > k$ .**



## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Annahme: Es gibt  $C^*$  mit  $\text{cost}(P, C^*) \leq r$  und  $|C^*| \leq k$  und  $|C| > k$ .
- Sei  $C$  die Menge der Zentren, die  $k$ -Center1 auswählt
- Da  $C \subseteq P$  gibt es für jedes  $p \in C$  (mindestens) ein  $c^* \in C^*$  mit  $\text{dist}(p, c^*) \leq r$
- Wir nennen  $c^*$  nah zu  $p$
- Behauptung: Kein  $c^*$  kann nah zu zwei  $p \in C$  sein (Beweis später)
- Damit folgt:  $|C^*| \geq |C|$  und somit Widerspruch zu  $|C^*| \leq k$  und  $|C| > k$ .

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- **Behauptung:** Kein  $c^*$  kann nah zu zwei  $p \in C$  sein
- **Beweis der Behauptung:**

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Behauptung: Kein  $c^*$  kann nah zu zwei  $p \in C$  sein
- Beweis der Behauptung:
- Alle Paare von Zentren  $p, q$  aus  $C$  haben Abstand  $> 2r$

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Behauptung: Kein  $c^*$  kann nah zu zwei  $p \in C$  sein
- Beweis der Behauptung:
- Alle Paare von Zentren  $p, q$  aus  $C$  haben Abstand  $> 2r$
- Wäre nun für ein Zentrum  $c^*$   $\text{dist}(p, c^*) \leq r$  und  $\text{dist}(q, c^*) \leq r$ , so würde  $\text{dist}(p, q) \leq \text{dist}(p, c^*) + \text{dist}(c^*, q) = \text{dist}(p, c^*) + \text{dist}(c^*, q) \leq 2r$  gelten.  
Widerspruch!

## Approximationsalgorithmen

### *Lemma 82*

Wenn Algorithmus  $k$ -Center1 mehr als  $k$  Zentren auswählt, dann gilt für jede Menge  $C^* \subseteq P$  von  $k$  Zentren, dass  $\text{cost}(P, C^*) > r$  ist.

### *Beweis (durch Widerspruch)*

- Behauptung: Kein  $c^*$  kann nah zu zwei  $p \in C$  sein
- Beweis der Behauptung:
- Alle Paare von Zentren  $p, q$  aus  $C$  haben Abstand  $> 2r$
- Wäre nun für ein Zentrum  $c^*$   $\text{dist}(p, c^*) \leq r$  und  $\text{dist}(q, c^*) \leq r$ , so würde  $\text{dist}(p, q) \leq \text{dist}(p, c^*) + \text{dist}(c^*, q) = \text{dist}(p, c^*) + \text{dist}(c^*, q) \leq 2r$  gelten. Widerspruch!

## Approximationsalgorithmen

### *Was, wenn wir $r$ nicht kennen?*

- Wir wissen nicht, welche Punkte Distanz größer als  $2r$  von den bisher ausgewählten Zentren haben
- Idee: Wähle immer den am weitesten entfernten Punkt, d.h. der  $\text{dist}(p, C)$  maximiert
- Gibt es einen Punkt mit  $\text{dist}(p, C) > 2r$ , dann ist es dieser

## Approximationsalgorithmen

k-Center2( $P, k$ )

1. Wähle beliebigen Punkt  $p \in P$  und setze  $C \leftarrow \{p\}$
3. **while**  $|C| < k$  **do**
3.     Wähle Punkt  $p \in P$ , der  $\text{dist}(p, C)$  maximiert
4.      $C \leftarrow C \cup \{p\}$
5. **return**  $C$

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Zunächst zur Laufzeit:



## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Zunächst zur Laufzeit:
- Um den Algorithmus in  $\mathbf{O}(nk)$  Zeit zu implementieren, müssen wir jeden Schleifendurchlauf in  $\mathbf{O}(n)$  Zeit erledigen können. Dazu speichern wir uns für jeden Punkt  $p$  den Wert  $\text{dist}(p, C)$ .

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Zunächst zur Laufzeit:
- Um den Algorithmus in  $\mathbf{O}(nk)$  Zeit zu implementieren, müssen wir jeden Schleifendurchlauf in  $\mathbf{O}(n)$  Zeit erledigen können. Dazu speichern wir uns für jeden Punkt  $p$  den Wert  $\text{dist}(p, C)$ .
- Wird nun ein neues Zentrum  $c$  in  $C$  eingefügt, so müssen wir nur für jeden Punkt überprüfen, ob  $\text{dist}(p, c) < \text{dist}(p, C)$  ist und ggf.  $\text{dist}(p, C)$  aktualisieren. Dies geht insgesamt in  $\mathbf{O}(n)$  Zeit.

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Zunächst zur Laufzeit:
- Um den Algorithmus in  $\mathbf{O}(nk)$  Zeit zu implementieren, müssen wir jeden Schleifendurchlauf in  $\mathbf{O}(n)$  Zeit erledigen können. Dazu speichern wir uns für jeden Punkt  $p$  den Wert  $\text{dist}(p, C)$ .
- Wird nun ein neues Zentrum  $c$  in  $C$  eingefügt, so müssen wir nur für jeden Punkt überprüfen, ob  $\text{dist}(p, c) < \text{dist}(p, C)$  ist und ggf.  $\text{dist}(p, C)$  aktualisieren. Dies geht insgesamt in  $\mathbf{O}(n)$  Zeit.

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Wir bezeichnen nun mit  $r$  die Kosten einer optimalen Lösung  $C^*$ .  
Annahme: Algorithmus liefert Menge  $C$  mit Kosten  $> 2r$ .

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Wir bezeichnen nun mit  $r$  die Kosten einer optimalen Lösung  $C^*$ .  
Annahme: Algorithmus liefert Menge  $C$  mit Kosten  $> 2r$ .
- Dann gibt es einen Punkt  $p$  mit  $\text{dist}(p, C) > 2r$ .

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Wir bezeichnen nun mit  $r$  die Kosten einer optimalen Lösung  $C^*$ .  
Annahme: Algorithmus liefert Menge  $C$  mit Kosten  $> 2r$ .
- Dann gibt es einen Punkt  $p$  mit  $\text{dist}(p, C) > 2r$ .
- Da der Algorithmus immer den Punkt auswählt, der maximalen Abstand zu den bisher ausgewählten Zentren hat, haben alle ausgewählten Zentren Abstand  $> 2r$  zur den bisher ausgewählten Zentren

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Wir bezeichnen nun mit  $r$  die Kosten einer optimalen Lösung  $C^*$ .  
Annahme: Algorithmus liefert Menge  $C$  mit Kosten  $> 2r$ .
- Dann gibt es einen Punkt  $p$  mit  $\text{dist}(p, C) > 2r$ .
- Da der Algorithmus immer den Punkt auswählt, der maximalen Abstand zu den bisher ausgewählten Zentren hat, haben alle ausgewählten Zentren Abstand  $> 2r$  zur den bisher ausgewählten Zentren
- **Somit würde Algorithmus k-Center1 auf dieser Eingabe mehr als  $k$  Zentren zurückgeben. Damit gilt nach Lemma 82  $\text{cost}(P, C^*) > r$ . Widerspruch!**

## Approximationsalgorithmen

### Satz 83

Algorithmus k-Center2 ist ein 2-Approximationsalgorithmus für das diskrete  $k$ -Center Clustering Problem. Algorithmus k-Center2 kann mit Laufzeit  $\mathbf{O}(nk)$  implementiert werden.

### Beweis

- Wir bezeichnen nun mit  $r$  die Kosten einer optimalen Lösung  $C^*$ .  
Annahme: Algorithmus liefert Menge  $C$  mit Kosten  $> 2r$ .
- Dann gibt es einen Punkt  $p$  mit  $\text{dist}(p, C) > 2r$ .
- Da der Algorithmus immer den Punkt auswählt, der maximalen Abstand zu den bisher ausgewählten Zentren hat, haben alle ausgewählten Zentren Abstand  $> 2r$  zur den bisher ausgewählten Zentren
- Somit würde Algorithmus k-Center1 auf dieser Eingabe mehr als  $k$  Zentren zurückgeben. Damit gilt nach Lemma 82  $\text{cost}(P, C^*) > r$ . Widerspruch!



## Approximationsalgorithmen

### *Zusammenfassung & Kommentare*

- Man kann viele Probleme approximativ schneller lösen als exakt (für die drei Beispiele sind keine Algorithmen mit Laufzeit  $\mathbf{O}(n^c)$  für eine Konstante  $c$  bekannt)
- Gierige Algorithmen sind häufig Approximationsalgorithmen